

ADATBÁZISOK

Kormány Zsolt

2017. január 9.

A jegyzet és annak forrása megtalálható a `bme-notes.github.io` weboldalon.

Közreműködtek: Bognár Márton

Kellemes vizsgázást!

Tartalomjegyzék

Előszó	1
Tételek es bizonyítások	2
Jegyzet összefoglaló	7
Alapfogalmak	7
Relációk	7
Relációs lekérdezések optimalizálása	7
Hálós adatbázisok	9
Objektumorientált adatbázis-kezelő rendszerek	9
Relációs adatbázisok logikai tervezése	11
Tranzakció kezelés	12
Időbélyeges tranzakciókezelés	13
Tranzakcióhibák és az időbélyegek	13
Verziókezeléssel	13
Elosztott eset	13
Fizikai Adatszervezés	14
Elosztott Adatbázisok	15
Gyakorlat - Gondolkodtató kérdések	17
Első gyakorlat	17
Második gyakorlat	17
Harmadik gyakorlat	17
Negyedik gyakorlat	17
Ötödik gyakorlat	17
Hatodik gyakorlat	17
Definíciók	19
 Előszó	
Lórem ipsum	

Tételek es bizonyítások

Tétel: MZ/X használhatatlan cuccokat küld

Minden az $R_k^{(n_k)} \subseteq A^{n_k}$, $(k = 1, 2, \dots, r)$ relációalgebrai kifejezéshez van olyan ψ sorkalkulus formula, hogy ψ csak az $R_k^{(n_k)}$ -k közül tartalmaz relációkat és az E kifejezés megegyezik $\{s^{(m)} | \psi(s^{(m)})\}$

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

Az E kifejezésben található műveletek száma szerinti teljes indukcióval. $n = 0$ azaz nincs művelet E-ben, e csak egyetlen relációt tartalmazhat pl. $R_k^{(n_k)}$ -t így

$E = \{s^{(n_k)} | R_k^{(n_k)}(s^{(n_k)})\}$ T.f.h E-ben n művelet van és az állítás még igaz. Igaz-e $n+1$ műveletre is?

Igaz volt tehát: $E_1 = \{t_1^{(n)} | \psi_1(t_1^{(n)})\}$ és $E_2 = \{t_2^{(m)} | \psi_2(t_2^{(m)})\}$

1. $\cup \rightarrow E = E_1 \cup E_2 (n = m) : E := \{t^{(n)} | \psi_1(t^{(n)}) \vee \psi_2(t^{(n)})\}$
2. $- \rightarrow E = E_1 - E_2 (n = m) : E := \{t^{(n)} | \psi_1(t^{(n)}) \wedge \neg \psi_2(t^{(n)})\}$
3. $\times \rightarrow E = E_1 \times E_2 (k = n + m) : E := \{t^{(k)} | \exists t_1^{(n)} \exists t_2^{(m)} \psi_1(t^{(n)}) \wedge \psi_2(t_2^{(m)}) \wedge t^{(k)}[1] = t_1^{(n)}[1] \wedge t^{(k)}[2] = t_1^{(n)}[2] \wedge \dots \wedge t^{(k)}[n] = t_1^{(n)}[n] \wedge t^{(k)}[n+1] = t_2^{(m)}[1] \wedge \dots \wedge t^{(k)}[n+m] = t_2^{(m)}[m]\}$
4. $\pi E = \pi_{i_1, i_2, \dots, i_r}(E_1) \rightarrow E := \{t^{(r)} | \exists u^{(n)} \psi_1(u^{(n)}) \wedge t[1] = u[i_1] \wedge t[2] = u[i_2] \wedge \dots \wedge t[r] = u[i_r]\}$
5. $\sigma E = \sigma_F(E_1) \rightarrow E := \{t^{(n)} | \psi_1(t^{(n)}) \wedge F'\} F' = F \wedge F$ i edik komponensét átírjuk $t^{(n)}[i]$ -re

Tétel: MZ/X használhatatlan cuccokat küld

Rögzített A interpretációs halmaz és $R_k^{(n_k)} \subseteq A^{n_k}$ relációk esetén a sorkalkulus bármely kifejezéséhez létezik az oszlopkalkulusnak olyan kifejezése, amely az előzővel azonos relációt határoz meg.

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

$\{s^{(m)} | \psi(s^{(m)})\} \iff \{x_1, x_2, \dots, x_m | \psi'(x_1, x_2, \dots, x_m)\}$ innentől ugyan az mint a sorkalkulus megfelelője!

Tétel: MZ/X használhatatlan cuccokat küld

(Igasság tétel)

Armstrong axiómák igazak, alkalmazásukkal csak igaz függőségek állíthatók elő.

Formálisan: $F \vdash_R X \rightarrow Y \Rightarrow F_R \models X \rightarrow Y$

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

...easy

Tétel: MZ/X használhatatlan cuccokat küld

Adott függéshalmazzal ekvivalens minimális függéshalmaz mindig előállítható.

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

Adott egy F függéshalmaz

1. $X \rightarrow Y \in F$ Helyettesíthető $X \rightarrow Y_1, \dots, X \rightarrow Y_n$ -el ahol $Y = \{Y_1, \dots, Y_n\}$
Így F' -t kapjuk. (nyilvánvalóan $F' = F$)
2. $\forall S \rightarrow C \in F'$ függőségre, ahol $S = \{S_1, \dots, S_n\}$ hogy elhagyható e valamely S_i attribútum.
Definíció szerint ehhez az kell hogy $(F'')^+ = (F')^+$

$$F'' = F' \setminus \{S \rightarrow C\} \cup \{S_1, S_2, \dots, S_{i-1}, S_{i+1}, \dots, S_n \rightarrow C\}$$

Ekkor ez ekvivalens $F' \subseteq (F'')^+$ és $F'' \subseteq (F')^+$ egyidejű fennállásával.

- $F' \subseteq (F'')^+ \Leftrightarrow C \in S^+(F'')$ - triviálisan teljesül
- $F'' \subseteq (F')^+ \Leftrightarrow C \in (S_1, S_2, \dots, S_{i-1}, S_{i+1}, \dots, S_n)^+(F')$

3. Vizsgáljuk meg $\forall Z \rightarrow B \in F''$ elhagyható-e.

Ehhez az kell, hogy $(F'' \setminus \{Z \rightarrow B\})^+ = (F'')^+$ fennáljon, de ez költséges.

$$(F'' \setminus \{Z \rightarrow B\})^+ = (F'')^+ \Leftrightarrow B \in Z^+(F \setminus \{Z \rightarrow B\})$$

Eredményeül egy F''' függéshalmazt kapunk mely továbbra is ekvivalens F -el, és minimális

Tétel: MZ/X használhatatlan cuccokat küld

BCNF és 3NF Def ekvivalencia

Tétel: MZ/X használhatatlan cuccokat küld

Ha egy séma $3NF \implies 2NF$ is

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

Indirekt ($\neg 2NF \rightarrow \neg 3NF$)

Legyen $A \in R$ másodlagos attribútum, K egy kulcs, amelyekre $K \rightarrow A$, továbbá $\exists K' \subset K$, hogy $K' \rightarrow A$ is igaz.

$K' \not\rightarrow K$, különben K szuperkulcs lenne.

$A \notin K$, mert A másodlagos attribútum, tehát 1 kulcsnak sem lehet eleme.

Tehát: $K \rightarrow K', K' \not\rightarrow K, K' \rightarrow A, A \notin K'$ Ami épp azt jelenti hogy A tranzitívan függ K től 3NF el ellentmondásba.

Tétel: MZ/X használhatatlan cuccokat küld

A BCNF sémákra illeszkedő relációk nem tartalmaznak redundanciát. (funkcionális függés következtében)

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

T.f.h van még redundancia. Ez azt jelenti, hogy van 2 sor, hogy egy A attribútum értékét a t sor értékei alapján t' sorba nem írhatjuk be tetszőlegesen.

	X	Y	A
t	x	y ₁	a
t'	x	y ₂	?

Látható hogy X értékek azonosak, míg léteznek olyanok melyek különböznek (Y). T.f.h a definiált függőségi kapcsolatok miatt ? helyére a-t kell írniunk.

Ez azt jelenti hogy létezni e kell egy $(Z \subseteq X) Z \rightarrow A$ függőségnek.

- Z nem lehet szuperkulcs, mert ekkor t és t' nek megkéne egyeznie
- Ha Z nem szuperkulcs akkor $Z \rightarrow A$ ellentmond a BCNF definíciójának.

Tétel: MZ/X használhatatlan cuccokat küld

Adott egy R séma és egy $\rho(R_1, R_2, \dots, R_n)$ felbontása. $\forall r(R)$ relációra $r \subseteq m_\rho(r)$. (Tetszőleges felbontás esetén, sorok nem tűnhetnek el, csak újak keletkezhetnek.)

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

Vegyünk egy tetszőleges $t \in r$ sort. Képezzük t vetületeit az R_i részsémákra, legyen ez $t[R_i]$, amely nyilván eleme az i -edik rész-relációnak. Ez a vetület nem változik $m_\rho(r)$ -ben sem, és a természetes illesztés tulajdonságai miatt $m_\rho(r)$ valamely sorában valamennyi $t[R_i]$ megjelenik. Így $t \in m_\rho(r)$

Tétel: MZ/X használhatatlan cuccokat küld

Adott az R séma, a séma attribútumain értelmezett F függőség-halmaz és egy $\rho = (R_1, R_2)$ felbontás.
 ρ veszteségmentes $\iff (R_1 \cap R_2) \rightarrow (R_1 \setminus R_2) \in F^+$ vagy $(R_1 \cap R_2) \rightarrow (R_2 \setminus R_1) \in F^+$

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza**Tétel: MZ/X használhatatlan cuccokat küld****Táblázatos módszer veszteségmentes felbontáshoz**

A ρ felbontás veszteségmentes \iff van csupa 'a'-ból álló sor

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza**Tétel: MZ/X használhatatlan cuccokat küld**

Minden R relációs séma és a sémán értelmezett F függőség-halmaz esetén $\exists \rho$ sémafelbontás, amely veszteségmentes és függőségörző, továbbá $\forall R_i \in \rho$ -ra R_i 3NF tulajdonságú

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

Konstrukció:

Képezzük az adott függőség-halmaz egy minimális fedését. Legyen ez G . Ha $G = \{X_1 \rightarrow A_1, X_2 \rightarrow A_2, \dots, X_n \rightarrow A_n\} \implies \rho = \{X_1 A_1, X_2 A_2, \dots, X_n A_n\} \cup \{K\}$

1. Függőségörző: Részsémákra vetítjük és megnézzük következnek-e az eredeti függések. ✓

2. Miért veszteségmentes? A kulcs sorába megmutatjuk, hogy csupa 'a' lesz.

Képezzük $K^+(F)$: K, B_1, B_2, \dots, B_m . Nyilván $K \cup \{B_1, B_2, \dots, B_k\} = R$

Ekkor B_i -k sorrendjébe lehetőségünk van 'a'-kat írni a táblázatba:

t.f.h i. attribútumig bővíthető volt a táblázat, az i. attribútum helyére azonban nem tudtunk 'a'-t írni. De

\exists egy olyan $Y \rightarrow B_i$ funkcionális függés, hogy $Y \subseteq K \cup \{B_1, B_2, \dots, B_{i-1}\}$, de konstrukció miatt $\exists Y B_i$ részséma, ahol $Y B_i$ sorában B_i alatt 'a' van. Így K helyére is kerülhet 'a'. ✓

3. 3NF?

Tétel: MZ/X használhatatlan cuccokat küld

Minden 1NF reláció felbontható 2NF relációkba úgy, hogy azokból az eredeti reláció torzulás nélkül helyreállítható

Tétel: MZ/X használhatatlan cuccokat küld

Minden, legalább 1NF R sémának létezik veszteségmentes felbontása BCNF sémákba.

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

Iteratívan kezdjük. Az iteráció minden fázisában igaz lesz, hogy a pillanatnyi felbontás veszteségmentes.

1. Ha R az adott F függőséget mellett BCNF, akkor nincs tennivaló, készen vagyunk.
2. Ha R nem BCNF, akkor $\exists X \rightarrow A \in F^+$, ami megsérti a BCNF tulajdonságokat, azaz $A \notin X$ és X nem szuperkulcsa R -nek.
Legyen ekkor a felbontás $\rho = (XA, R \setminus A)$
Ez továbbra is veszteségmentes.
3. BCNF-e már? akkor ugyanez előről a részsémákra.

Tétel: MZ/X használhatatlan cuccokat küld

Adott időpillanatban nincs patt \iff a várakozási gráfban nincs kör (azaz a gráf irányított körmentes gráf, Directed Acyclic Graph, DAG)

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

\rightarrow (indirekt, Van kör \rightarrow van patt) t.f.h. van kör. Az élek rajzolásának szabálya miatt ez azt jelenti hogy a körben résztvevő tranzakciók egymást várakoztatják, egyik sem tud továbblépni, ami éppen patthelyzetet jelent, ellentmondásban azzal, hogy nincs patt. Tehát ha nincs patt, akkor nem lehet kör a várakozási gráfban.

\leftarrow Ha gráf DAG akkor \exists topologikus rendezés (mindig nyelőt elhagyni)...

Tétel: MZ/X használhatatlan cuccokat küld

Egy S ütemezés sorosítható \iff a sorosítási gráf DAG

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

Előzővel azonos módon.

Tétel: MZ/X használhatatlan cuccokat küld

Ha egy legális ütemezés valamennyi tranzakciója 2PL Protokollt követi \implies az ütemezés sorosítható

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

Rendezzük a tranzakciókat a növekvő zárpontjuk szerinti sorrendbe. Ez soros ekvivalens lesz:

T.f.h az ütemezésben a T_i : LOCK A, után T_j : LOCK A következik ($T_i \rightarrow T_j$). Ehhez nyilván az kell hogy T_i tetszabadítja a zárat A-n, mielőtt T_j LOCK A következne. Viszont T_i is kétfázisú, így meg kell hogy kapja valamennyi zárját T_j LOCK A előtt. Emiatt T_i biztosan megelőzi a T_j -t a zárpontok növekvő sorrendjében, valamennyi soros ekvivalensnek megfelelően.

Tétel: MZ/X használhatatlan cuccokat küld

A fa protokollnak eleget tevő legális ütemezések sorosíthatók.

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

A sorosíthatósági gráf körmentes...

Tétel: MZ/X használhatatlan cuccokat küld

A figyelmeztető protokollt követő legális ütemezések konfliktusmentesek (a) és sorosíthatók (b).

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

1. A protokoll szabályai biztosítják hogy bármely tranzakció csak akkor tehesen zárte egy adategységre, ha figyelmeztetés van annak valamennyi ősen. Emiatt egyidejűleg más tranzakció nem tehet zárat az adategységnek egyetlen ősére sem, tehát nem alakulhat ki zárkonfliktus.
2. Ekvivalens S ütemezés konstruálása, melyben minden adategységet explicit zárolunk:
 - (a) Összes WARN és hozzá tartozó UNLOCK törlése
 - (b) LOCK X esetén explicit zár X összes gyerekére is.
 - (c) UNLOCK X estén, eltávolítjuk a zárat X gyerekeiről is.

Ezután S legális, mert R is legális volt, és semmi olyat nem tettünk ami miatt illegálissá válhatna, továbbá kétfázisú, mert R is kétfázisú volt és ez az átalakítás során a kétfázisú tulajdonság megmaradt. Ezek elégséges feltételek S sorosíthatóságához

Tétel: MZ/X használhatatlan cuccokat küld

A szigorú kétfázisú protokoll (2PL)-t követő tranzakciókból álló ütemezések \implies Sorosíthatók és Lavinamentesek.

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza

2PL miatt sorosítható, mivel nem olvashatnak piszkos adatot, ezért lavina mentes is.

Tétel: MZ/X használhatatlan cuccokat küld

A globális zár kompatibilitási mátrix azonos a WALL protokoll mátrixával.

Bizonyítás: Hufnágel Pisti jobb ember, mint Mészga Géza**Tétel: MZ/X használhatatlan cuccokat küld**

objektum orientált példák könyvbe

Tétel: MZ/X használhatatlan cuccokat küld

Hálos adatbázis tervezése relac semabol

Tétel: MZ/X használhatatlan cuccokat küld

Balazs feladatai

Jegyzet összefoglaló

Alapfogalmak

Adatbázis kezelőt jellemző tulajdonságok:

- nagy adatmennyiség
- gazdag struktúra
- hosszú élettartam

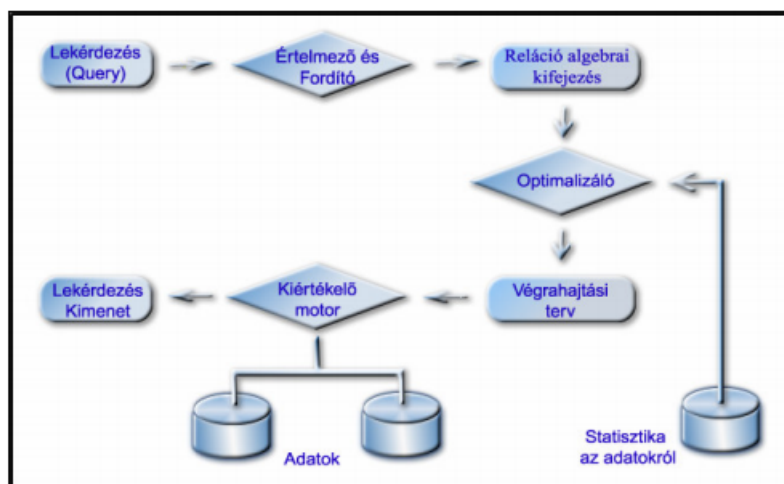
HDD vel foglalkozunk (mágneslemezes tár)

Relációk

Reláció számossága: A sorok száma

Reláció aritása: Attribútumok/Oszlopok száma

Relációs lekérdezések optimalizálása



Ábra 1.1A lekérdezés feldolgozás tipikus lépései

Lépések:

1. Fordítás

PL: SQL nyelvét szintaktikailag ellenőrizzük és ha helyes egy Reláció algebrai kifejezésre képezzük le

2. Végrehajtási terv készítése az adatok alapján

Egy adott lekérdezést többféleképpen is el tudunk készíteni, ezek közül a leoptimalisabbat keressük.

A katalógusban adatokat találunk a relációkról:

- $n_r(\text{number})$: az r relációban lévő rekordok száma
- $b_r(\text{blocks})$: az r relációban lévő rekordokat tartalmazó blokkok száma
- $s_r(\text{size})$: egy rekord nagysága byte-okban
- $f_r(\text{blocking factor})$: mennyi rekord fér el egy blokkba
- $V(A, r)(\text{Values})$: Hány különböző értéke fordul elő az A attribútumnak az r relációban
 $V(A, r) = |\pi_A(r)|$; Ha A kulcs $\rightarrow V(A, r) = n_r$ (sorok száma)
- $SC(A, r)(\text{Selection Cardinality})$: Azon rekordok átlagos száma, amelyek kielégítenek egy egyenlőségi feltételt az A attribútumra feltéve, hogy legalább egy rekord kielégíti ezt az egyenlőségi feltételt.
 $SC(A, r) = \frac{n_r}{V(A, r)}$, Ez csak akkor igaz ha egyenletesen oszlanak el a különböző értékek
 Ha A kulcs $\rightarrow SC(A, r) = 1$

Egyéb adatok B* fák/Hash táblákról

- f_i : Az átlagos pointer-szám a fa struktúrájú indexek csomópontjaiban, mint pl. a B* fáknál, azaz a csomópontokból induló ágak átlagos száma
- HT_i (Height of tree) : Az i index színjeinek a száma, azaz az index magassága B* fáknál
 $B^* \rightarrow HT_i = \lceil \log_{f_i} V(A, r) \rceil$ Hash-indexnél $\rightarrow HT_i = 1$
- LB_i (Lowest level index Block): Az i index legalsó szintű blokkjainak a száma, azaz a levélszintű indexblokkok száma

Keresési (szelekciós) algoritmusok:

(a) Alap algoritmusok:

i. Lineáris keresés: $E = b_r$

ii. Bináris keresés: $E = \lceil \log_2 b_r \rceil + \left\lceil \frac{SC(A, r)}{f_r} \right\rceil - 1$

Megtalálás \log_2 után még van SC/f_r rekord, -1 pedig azért mert az első blokk az benne van a megtalálásba

(b) Indexelt szelekciós algoritmusok

- Elsődleges index:

Az elsődleges index a rekordok olyan sorrendben való olvasását teszi lehetővé, amely megfelel a rekordok fizikai tárolási sorrendjének. Egyébként Másodlagos Index.

- Másodlagos index:

i. Elsődleges indexel, egyenlőségi feltételt a kulcson vizsgálva.

$$E = HT_i + 1$$

ii. Elsődleges index, de egyenlőségi feltétel nem a kulcson

$$E = HT_i + \left\lceil \frac{SC(A, R)}{f_r} \right\rceil$$

iii. Másodlagos index használatával

$$E = HT_i + SC(A, r)$$


$$E = HT_i + 1 \text{ ha } A \text{ egyediséget biztosít}$$

(c) Összehasonlítás alapú szelekció

i. Elsődleges indexel: $E = HT_i + b_r/2$

ii. Másodlagos index: $E = HT_i + \frac{LB_i}{2} + \frac{n_r}{2}$

Join típusok



(a) Nested-loop join: $b_r + n_r \cdot b_s - 2$ for ciklus

minden n_r rekordhoz beolvasom a hozzá tartozó b_s blokkot és még beolvasom az összes b_r blokkot is.

(b) Block nested -loop join : $b_r \cdot b_s + b_r$

Kihasználja hogy blokkok kerülnek a memóriába, 1-1 beolvasott blokk összes összehasonlítása, majd újabb blokk beolvasása. A képen a piros blokk csak akkor kerül beolvasásra ha fekete-zöld blokk összes rekordja össze volt már hasonlítva.

- (c) Indexed nested-loop join: $b_r + n_r \cdot c$ ahol c a szelekció költsége s-en
 (d) Merge join: $b_r + b_s + a$ - ahol a a rendezés költsége
 Nagy adathalmazoknál általában ez a legoptimálisabb
 (e) Hash join: $b_r + n_r \cdot h_s$ - Ahol h_s egy blokk elérési ideje vödrön belül

Kiértékelési terv készítésénél exponenciálisan növekszik a lehetséges elrendezések száma, a joinok számának növekedésével. Ezért egy lokálisan optimális megoldást választunk ki!

CÉL: A LEGGYORSABB ALAK KIVÁLASZTÁSA **MÁSODIK LÉPÉS: SZELEKCIÓK SÜLLYESZTÉSE** **HARMADIK LÉPÉS: LEVELEK ÁTRENDÉZÉSE**

Kiindulás: kanonikus alakból (Descartes, szűrés, projekció)



NEGYEDIK LÉPÉS: JOIN



ÖTÖDIK LÉPÉS: PROJEKCIÓ SÜLLYESZTÉSE



Hálós adatbázisok

Set típusok szintjén modellezünk

Definíció: Set típus

Legyen R_1 és R_2 két rekord típus és legyenek $F(R_1)$ és $F(R_2)$ a konkrét esetek halmazai. Ekkor az S set típust az $S := R_1 \times R_2$ művelettel definiálhatjuk, ami egy $F(R_2) \rightarrow F(R_1)$ függvényszerű kapcsolatot ír le. R_1 - *owner* típus, R_2 - *member* típus

Set

- Egyenrangú *member*-rekordoknak egy (akár üres) halmazából, és
- Pontosan egy *owner*-rekordból áll, aminek a member-rekordok alárendeltek.

Objektumorientált adatbázis-kezelő rendszerek

Problémák a Relációs-adatbázisokkal:

- Nincsenek *rekurzív* lekérdezések.
 PL: Dolgozók, beosztottak reláció

2. "lista" jellegű információk tárolására nem alkalmas

PL: Grafika: Egy fonal tetszőleges számú töréspontjának tárolása


3. Autó, Garázs példa ...

Típuskonstruktorok

- Halmazkonstruktor: $T_{set} = \mathbf{SET\ OF}(A : T)$, ahol A attribútum, T pedig az attribútum típusa. A halmaz típus legfontosabb jellemzője, hogy elemei rendezetlenek.
- Listakonstruktor: $T_{list} = \mathbf{LIST\ OF}(A : T)$, ahol A attribútum, T pedig az attribútum típusa. A lista típusra jellemző, hogy elemei szekvenciálisan rendezettek. A programozási nyelvek láncolt listájával analóg struktúra kialakítására ad lehetőséget.
- Tuplekonstruktor: $T_{tuple} = \mathbf{TUPLE\ OF}(A_1 : T_1, \dots, A_n : T_n)$, ahol A_i attribútum, T_i pedig az A_i attribútum típusa. A tuple típus a relációs modellben a reláció egy elemének felel meg. (C struct)


Objektumok között asszociációk vannak. Ez lehet akár kétirányú is.

PL:



Az ábrán vastaggal jelölt vonalak mentén terjed a terjedési tulajdonság. Ha valamelyik őse elpusztul akkor az összes vastaggal jelölt leszármazottja is (rekurzió). Ha elpusztul a fészek \rightarrow elpusztulnak a fiókák, és a tojások, de a madarak nem.

Relációs adatbázisok logikai tervezése



Anomáliák

1. Módosítási anomália
2. Beszúrási anomália
3. Törlési anomália

NÉV	CÍM	TÉTEL	ÁR
Tóth István	Bp. Fa u. 5.	tégla	30
Tóth István	Bp. Fa u. 5.	vas	200
Kis János	Baja Ó u. 9.	tégla	40
Kis János	Baja Ó u. 9.	pala	20
Nagy Géza	Ózd Petőfi u. 11	cement	350

Tranzakció kezelés

ACID

atomicity - tranzakció lefutása úgy hogy minden lefut belőle

konzisztencia - az adatbázisba csak a sikeresen lefutott tranzakciók vannak

Def: Soros ütemezés \Rightarrow izolált tranzakció

DE izolált \nRightarrow Soros

Átlapolódásból adódó problémák:

1. Dirty read
2. Phantom read
3. Lost update
4. Non-repetable read

A sorosítással ezek a problémák elkerülhetők.

Problémák a záarakkal - Deadlock megoldási lehetőségek

Definíció: Lavina

Több piszkos adat olvasása, mely lavina szerűen terjed

Definíció: Agresszív protokoll

Optimista konkurenciakezelés. Egy protokoll agresszív, ha megpróbál olyan gyorsan lefutni, amennyire csak lehetséges, nem törődve azzal, hogy ez esetleg abortoz is vezethet. (Keveset foglalkozik a záarakkal)

PL: Záarakat szigorúan olvasás/írás előtt kéri.

Definíció: Konzervatív protokoll

Pesszimista konkurencia kezelés. Egy protokoll konzervatív, ha megkísérli elekrülni az olyan tranzakciók futását amelyek nem biztos, hogy eredményesek lesznek (Sokat foglalkozik a záarakkal)

PL:

1. Szigorú 2PL (Lavina mentes és sorosítható)
2. Az összes zárat előre kéri, és csak akkor indul, ha már az összeset megkapta (Patmentes)
3. csak akkor kap meg egy zárat, ha az előtte senkinek nem kell az adatelemhez tartozó várakozó sorban. (Éhezésmentes)

Ellenőrzési pontok (checkpoint)

1. Ideiglenesen megtiltjuk új tranzakció indítását, és megvárjuk, amíg minden tranzakció befejeződik vagy abortál.
2. Megkeressük azokat a memóriablokkokat, amelyek módosultak, de még nem kerültek a háttértárba kiírásra,
3. Ezeket a blokkokat visszaírjuk a háttértárra.
4. Ellenőrzési pont (checkpoint) naplóba
5. naplót kiírjuk a háttértárra

Médiahibák elleni védekezés

- Rendszeres mentések (backup).

- Az adatbázis fájlok duplikálása lehetőleg egy másik fizikai eszközön, néha más földrajzi helyen (*elosztott adatbázisok*)

Fa protokoll - pl B* fa

Figyelmeztető protokoll - pl: Egy egész tábla lockolása relációs adatbázisba

Időbélyeges tranzakciókezelés

Sorosíthatóság biztosításának egy másik módja. Akkor praktikus, ha a tranzakciók között kevés a potenciális sorosítási konfliktus.

Mindig **Deadlock mentesek**

	T olvasni akar	T írni akar
$t(T) > R(A)$ $t(T) > W(A)$	✓ $R(A) := t(T)$	✓ $W(A) := t(T)$
$t(T) > R(A)$ $t(T) < W(A)$	×	× abort T Thomas szabály: T mehet
$t(T) < R(A)$ $t(T) > W(A)$	✓	×
$t(T) < R(A)$ $t(T) < W(A)$	×	×

Thomas szabály: T tovább mehet, hiszen senki nem használja amit ő írt bele, mert már előbb felülírták

Összefoglalva:

Olvasás: $t(T) \geq W(A)$ ✓

Írás: $t(T) \geq R(A) \wedge t(T) \geq W(A)$ ✓

Thomással írás: $t(T) \geq R(A)$

Tranzakcióhibák és az időbélyegek

Előfordulhat **inkonzisztencia**(lavinákból adódóan)

Megoldás:

- Elfogadjuk a lavinákat, hiszen az időbélyeges tranzakciókezelést tipikusan olyan környezetben használjuk, ahol kevés az abort, tehát a lavina még kevesebb
- Megakadályozzuk a piszkos adat olvasását pl: Commit ponting nem írunk adatbázisba

Lépései az alábbiak lennének:

1. Módosítások csak a munkaterületen végezve
2. Tranzakció eléri a készpontját
3. írások véglegesítése az adatbázison

Illetve előfordulhat, hogy a "lassú tranzakciók"ból adódóan, 1 adategységet hibásan olvasnak ki.

Megoldás: **Zárak** használata

Verziókezeléssel

Minden adatelem írásakor az előzőt megőrizzük.

Abort kell, ha T írni akar és $W(A_i) < t(T) < R(A_i)$ Tehát ha olyan adatot olvastunk, melyet most kéne a T tranzakciónak beírnia.

Elosztott eset

1. Időbélyeg kiegészítése egyedi azonosítóval csomóponttól függően
2. Minden lokális példányon el kell végezni a módosítást
3. PL: Wall protokoll szerint döntendő el hogy *READ A* érvényes-e (Egy $R(A_i)$ és $W(A_i)$ vizsgálat)

Fizikai Adatszervezés

1. Heap szervezés

- Lineáris keresés : $\frac{b_r + 1}{2}$

2. Vödrös Hash

- NINCSENEK KULCSOK TÁROLVA
- Vödrökön belül lineáris keresés

3. Indexelt állományok

- Támogatja a **több kulcs** szerinti keresést - Ez esetben több index állomány
- Index állományt mindig rendezve tartjuk

(a) **Sűrű index**

Mutató minden egyes adatrekordra.

Keresés $\log_2(b_r) - b_r = \text{indexállományblokkok száma}$

- **B* fa** $\implies \log_k(b_r)$ el arányos keresési idő, ahol k a szintek száma

(b) **Ritka index**

- Plusz helyigény
- Egyel több lapelérés
- Több adminisztrációval jár a karbantartása
- + Az adatállományt nem kell rendezetten tartani
- + Meggyorsítja a rekordelérést, mert a ritka index mérete jóval kisebb is lehet, mint egy sűrű index
- Támogatja a több kulcs szerinti keresést
- Az adatállomány rekordjai szabaddá tehetők ,ha minden további hivatkozás a sűrű indexen keresztül történik

Elosztott Adatbázisok

Hatékonyság: Szükséges üzenetváltások számával mérhető

Protokoll	adat üzenet	kontroll üzenet	"X"Lock A érvényessége
Wall írás	n	2n	LOCK $A_i \forall i$ -re (n)
Wall olvas	1	1	LOCK A_i min 1 re
Többségi írás	n	n+1	LOCK $A_i \frac{n+1}{2}$ -re
Többségi olvas	1	n+1	LOCK $A_i \frac{n+1}{2}$ -re
K az N-ből írás	n	2k	LOCK A_i k-ra
K az N-ből olvas	1	$2 \cdot (n+1-k)$	LOCK A_i n+1-k

Eddig a lokális adategységekért az egyes csomópontok zármenedzserei feleltek.

1. Elsődleges példányok módszere

- Egy konkrét csomópont zármenedzsere felügyeli a zárat: X_A
- PL: X_A az A adategység elsődleges példánya (van róla másolata)
- vagy Egy csomópont rendelkezhet több adategység felett is (centrális csúcs módszer)

2. Elsődleges példányok tokennel

PL: ATM (Országok között sok várakozás)

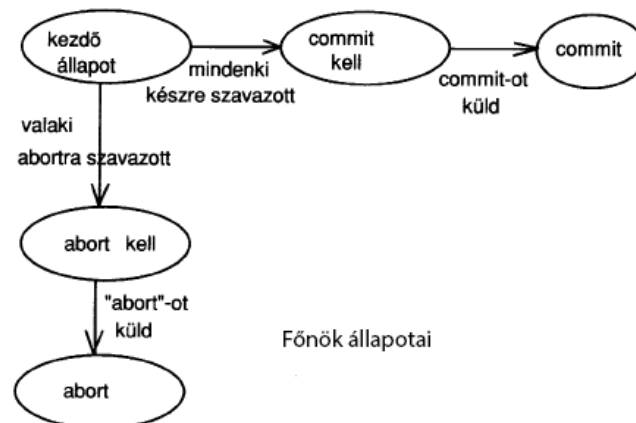
- Minden adategységre egy Írási: $WT(A)$ és egy olvasási: $RT(A)$ token
 - Ha $\exists WT(A) \rightarrow \neg RT(A)$
 - Ha nincs $WT(A) \rightarrow$ bármennyi $RT(A)$ létezhet
 - Ha X csomópontban van az $WR(A)$ token, akkor az X csomópont zármenedzsere jogosult RLOCK A vagy WLOCK A-t megítélni X csomópontban futó tranzakcióknak
 - Ha Y csomópontban a B adategységet írni akarja akkor ehhez $WT(B)$ -t az Y csomópontba kell juttatni, ha nem lenne ott. Ezt üzenetváltásokkal érheti el:
 - (A)-t válaszolnak , ha nincs náluk sem $RT(B)$ sem $WT(B)$, vagy lemondanak rála
 - (B)-t válaszolnak, ha van náluk $RT(B)$ vagy $WT(B)$
- Ha mindenki (A)-t küldött \Rightarrow Övé lehet, ezért körbeküldi mindenkinek hogy nála van, semmisítsek meg a B-re vonatkozó tokenjüket
- Ha 1db (B)-t is kap \Rightarrow Y visszavonja a kéréseket, azoktól akik (A)-t küldtek

3. Kétfázisú kész protokoll (2PC)

- Adott egy T logikai tranzakció, és számos T_i lokális tranzakció az N_i csomópontokban
- Az a csomópont ahol kezdeményezték a tranzakciót legyen **Főnök**, többi résztvevő
- 2 Állapot: Commit képes - Commit



10.2.3.a. ábra: Egy résztvevő állapotai



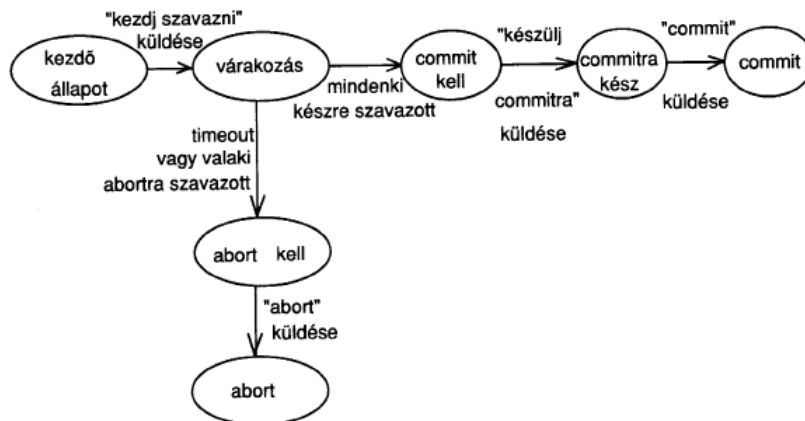
Főnök állapotai

4. 3 fázisú kész protokoll (3PC) - "Blokkolásmentes"

Commit képes - Commit kész - CCommit



10.2.4.a. ábra: Egy résztvevő fontosabb állapotai a 3PC protokollban



10.2.4.b. ábra: A főnök állapotai a 3PC protokollban

Értelmezés: Amikor egy résztvevő megkapja a "készülj commitra" üzenetet, akkor tudhatja, hogy mindenki készsre szavazott. A résztvevők ezt nyugtázzák, ezután küldi a főnök a "commit jön" üzenetet. Ha egy résztvevő ezt is veszi, akkor ebből már tudja hogy minde résztvevő már megtudta, hogy minden résztvevő commitra szavazott. Ezután commitálhat.

Gyakorlat - Gondolkodtató kérdések

Elso gyakorlat

Masodik gyakorlat

Harmadik gyakorlat

1. Az ER modellből milyen funkcionális függések olvashatók le? Ha ezeken kívül más függőség nem adott, akkor mit mondhatunk az ilyen módon származtatott adatbázisséma normálformájáról?
 - (a) Egy entitás kulcsa, egyértelműen meghatározza az adott entitást így ez egy funkcionális függés lenne.
 - (b) 1-N kapcsolat esetén, PL Tankör - diákok kapcsolatban a Tankör meghatározza a diákokat.
 - (c) 1-1 kapcsolat esetén, a meghatározás kölcsönös. PL Feleség - Férj Kapcsolat

Negyedik gyakorlat

Otodik gyakorlat

Hatodik gyakorlat

1. A naplózás tárhely igényét szeretnénk optimalizálni. Helyes-e a következő érvelés? Mivel egy tranzakciónak csak a COMMIT pontjára van szüksége a napóra - hisze na COMMIT utáni műveletek biztosan lefutnak -, ezért szigorú 2PL alkalmazásával megelőzzük a lavinahatást, és a COMMIT naplózása helyett így naplóból már törölhetjük az adott tranzakcióhoz tartozó bejegyzéseket (ha garantáljuk ezen törlés atomicitását.)

Nem, mert a COMMIT pont után még előfordulhat rendszer hiba, és előfordulhat hogy esetleg még az adatbázisba írás megse történt vagy az adott adategység megváltozott értéke még csak a memóriában van benne. Ez ekkor el fog veszni ha elmegy az áram például és nincs a naplóban.

Egy konzisztens állapot előtti bejegyzéseket (például checkpoint előttiakat), nyugodtan törölhetjük, hiszen ez már nem vesz el, végleges.

2. **Hogyan biztosítja a holtpontmentességet a 2PL?**

Nem vagyok benne biztos, de egy soros equivalens kikényszerítésével, hiszen ha egy ütemezés soros \Rightarrow akkor pattmentes.

3. Lehet-e konkurensen módosítani egy állományt, amire B* fa épül? Mikor lehet felszabadítani a gyökér elemet fogó zárat?

4. Miért fontos a sorosíthatóság?

Mert így elkerülhető a Dirty read, Phantom read, Lost update és a non-repetable read. Illetve egy soros equivalens Deadlock (pattmentes) és az izolációs elv teljesül, a tranzakció biztosan korrekt lesz.

5. Egy ütemezés nem sorosítható, ennek ellenére érvényes lehet-e az izolációs elv?

Igen, explicit kimondja a könyv, ha Soros \Rightarrow Izolált. Ezért Izolált \nRightarrow Soros

6. Ha a naplófájl tartalmaz minden információt a változásokról, akkor miért kell az adatbázis?

A naplófájl csak a változásokat tartalmazza, ha nem lenne adatbázis, akkor nem lenne meg az a kiindulási alap amihez képest a változásokat tároljuk.

Másrészről ha nincs adatbázis, csak napló akkor egy adatelem értékéhez a napló nagy részét végig kéne olvasni ,hogy megtaláljuk az értékét. (a keresés ideje exponenciálisan nőne)

7. Mikor érdemes 2PL-t és mikor érdemes időbélyeges tranzakciókezelést használni?

Időbélyegest ott használjuk ahol kevés az abort (konfliktus), hiszen ekkor hiba nélkül (lavina mentesen) működik. 2PL?

8. Mi történik egy sorosíthatósági gráffal, ha egy tranzakció abortál.

Ha létezik egy $T_1 \rightarrow T_2 \rightarrow T_3$ sorosítási gráf, és T_2 abortál akkor a csomópontba bemenő éleket a kimenő élek mentén "meghosszabítjuk". Jelen esetben $T_1 \rightarrow T_3$ lesz. T_1, T_3 esetén nincs dolgunk. Általános esetben ugyanez.

9. Időbélyeges tranzakciókezelés miként véd a holtpontra ellen?

Nincsenek záracok, így nem lehet holtpontra :)

Ha mégis záracokat használunk (mert van ilyen időbélyeges tranzakciókezelés is), akkor az adategységekhez egy megadott sorrendben rendelve a záracokat.

- 10.

Definíciók

Definíció: Mézga Géza

Azt az index állományt, amely nem kulcsmezőre tartalmaz indexeket, *invertált állománynak* nevezzük. Az index neve ekkor *másodlagos index*.

Definíció: Mézga Géza

Egyed(entitás) - A valós világban létező, logikai vagy fizikai szempontból saját léttel rendelkező dolog, amelyről adatokat tárolunk.

Definíció: Mézga Géza

A tulajdonság az, ami az entitásokat jellemzi, amelyen vagy amelyeken keresztül az entitások megkülönböztethetők.

Definíció: Mézga Géza

Egyedek halmaza (entity set): Az azonos attribútum-típusokkal jellemzett egyedek összessége.

PL: EMBER(név, születésnap) EMBER = Egyed-halmaz, Név = Attribútum-típus

Definíció: Mézga Géza

Kapcsolat - Entitások névvel ellátott viszonya

Definíció: Mézga Géza

1-1 kapcsolat: Olyan (bináris) kapcsolat, amelyben a résztvevő entitáshalmazok példányaival egy másik entitáshalmaznak legfeljebb egy példánya van kapcsolatban.

Definíció: Mézga Géza

Több-1 kapcsolat: Egy K:E1,E2 kapcsolat több-egy, ha E1 példányaival legfeljebb egy E2-beli példány tartozik.

Definíció: Mézga Géza

Egy kapcsolat több-több funkcionalitású, ha nem több-egy egyik irányban sem.

Definíció: Mézga Géza

Az ER modellezésnél az attribútumoknak azt a halmazát, amely az entitás példányaival egyértelműen azonosítja kulcsnak nevezzük.

Definíció: Mézga Géza

Halmazok Descartes-szorzatának részhalmazát relációnak nevezzük.

Definíció: Mézga Géza

$DOM(\Psi) = \{\Psi\text{-beli alaprelációk valamennyi attribútumának értékei}\} \cup \{\Psi\text{-ben előforduló konstansok}\}$

Definíció: Mézga Géza

$\{t \mid \Psi(t)\}$ biztonságos, ha

- minden $\Psi(t) - t$ kielégítő t minden komponense $DOM(\Psi)$ -beli és
- Ψ -nek minden $\exists u : \omega(u)$ formulára teljesül, hogy ha u kielégíti ω -t az ω beli szabad változók valamely értéke mellett $\rightarrow DOM(\omega)$ beli (a részformula biztonságos)

Definíció: Mézga Géza

Egy R rekord típus egy olyan $A_1, A - 2, \dots, A_n$ - n es (tupel) ahol A_i -k az attribútumnevek és minden A_i -hez egy D_i halmaz, az attribútum domain(értelmezési tartomány)-ja is hozzá tartozik, amely halmazból az A_i attribútum értéket vehet fel.

Definíció: Mézga Géza

Legyen R_1 és R_2 két rekord-típus és legyenek $F(R_1)$ és $F(R_2)$ a konkrét esetek halmazai. Ekkor az S set-típust az $S := R_1 \times R_2$ művelettel definiálhatjuk, ami egy $F(R_2) \rightarrow F(R_1)$ függvényszerű kapcsolatot ír le. R_1 az owner típus, R_2 pedig a member-típus

Definíció: Mézga Géza

Ha egy relációban valamely attribútum értékét a relációban található más attribútum(ok) értékéből ki tudjuk következtetni valamely ismert következtetési szabály segítségével akkor a relációt **redundánsnak** nevezzük.

Definíció: Mézga Géza

Funkcionális függés...

Definíció: Mézga Géza

$Ha X, Y \subset R \wedge X \rightarrow Y$, de Y nem függ funkcionálisan X egyetlen valódi részhalmazától sem, akkor X -et Y **determinánsának** nevezzük. Azt is mondhatjuk, hogy Y **teljesen függ** X -től. Ha van $X' \rightarrow Y$, akkor Y **részlegesen függ** X -től.

Definíció: Mézga Géza

Teljesen függés(jobb oldal) = determináns(bal oldal)

Definíció: Mézga Géza

X -et pontosan akkor nevezzük kulcsnak az R reláción, ha $X \rightarrow R \wedge \nexists X' : X' \subset X \wedge X' \rightarrow R$

Definíció: Mézga Géza

(igaz) egy adott R sémán az attribútumain értelmezett F_R függéshalmaz mellett egy $X \rightarrow Y$ függőség pontosan akkor igaz, ha minden olyan $r(R)$ reláción fennáll, amelyeken F_R valamennyi függősége is fennáll. Jelölése: $F_R \models X \rightarrow Y$

Definíció: Mézga Géza

(Levezethető) egy $W \rightarrow Z$ funkcionális függőség pontosan akkor vezethető le adott F_R függőségekből, ha az axiómák ismételt alkalmazásával F_R ből kiindulva megkaphatjuk $W \rightarrow Z$ -t Jelölése: $F_R \vdash W \rightarrow Z$

Definíció: Mézga Géza

Attribútum halmaz lezárása...

Definíció: Mézga Géza

Az F függéshalmaz lezárása mindazon függőségek halmaza, amelyek az F függéshalmaz elemeiből az Armstrong axiómák alapján következnek.

Formálisan: $F^+ = \{X \rightarrow Y \mid F \models X \rightarrow Y\}$

Definíció: Mézga Géza

Két függéshalmaz pontosan akkor ekvivalens ha lezártjaik megegyeznek.

EZ bonyolult helyette: $F \subseteq G^+ \wedge G \subseteq F^+$ egyaránt teljesül e

Definíció: Mézga Géza

Minimális függéshalmaz...

Definíció: Mézga Géza

1NF: Egy reláció 1NF, ha csak atomi attribútum-értékek szerepelnek bene.

Definíció: Mézga Géza

2NF: 1NF és benne minden másodlagos attribútum a reláció bármely kulcsától teljesen függ.

Definíció: Mézga Géza

3NF 1): 1NF és $\forall A \in R$ másodlagos attribútum és $\forall X \subseteq R$ kulcs esetén $\nexists Y$, hogy $X \rightarrow Y, Y \nrightarrow X, Y \rightarrow A, A \notin Y$

Definíció: Mézga Géza

3NF 2): 1NF és \forall nem triviális függőségre $X \rightarrow Y$ függőségre

X szuperkulcs vagy Y Elsődleges attribútum

Definíció: Mézga Géza

BCNF: 1NF és Kulcstól tranzitívan nem függ attribútum

Definíció: Mézga Géza

BCNF 2) 1NF és \forall nem triviális $X \rightarrow Y$ függőségre

X szuperkulcs

Definíció: Mézga Géza

Tranzitív függ...

Definíció: Mézga Géza

(Triviális függőség) Ha za X, Y attriúbútumhalmazokra igaz, hogy $Y \subseteq X$, akkor az $X \rightarrow Y$ függőséget triviális függőségnek nevezzük, egyébként a függőség nemtriviális.

Definíció: Mézga Géza

Egy R reláció $A \in R$ attribútuma elsődleges, ha A eleme a reláció valamely K kulcsának, egyébként A másodlagos attribútum.

Definíció: Mézga Géza

Egy R Relációs sémának.. felbontás

Definíció: Mézga Géza

Veszteségmentes felbontás....

Definíció: Mézga Géza

Adott az R séma attribútumain értelmezett függőségek F halmaza. A függőségeknek ez $Z \subset R$ attribútumhalmazra való vetítése a $\phi_z(F)$ függőség-halmaz, amelyre $\phi_z(F) = \{X \rightarrow Y | X \rightarrow Y \in F^+ \text{ és } XY \subseteq Z\}$

Definíció: Mézga Géza

Függőségörző...